

Segmentation clients RFM — Online Retail II

TAISS 2026 — Togo AI Summer School · Filière F1 (Data Science) · TP2

Équipe : [noms à compléter] — Lomé, août 2026

Dépôt : github.com/jack-junior/client-scope-rfm-project

1. Contexte

Un e-commerce britannique de cadeaux, opérant majoritairement en gros, cumule plus d'un million de transactions sur deux ans sans connaissance structurée de sa clientèle. Nous construisons une segmentation comportementale par la méthode RFM (Récence, Fréquence, Montant) suivie d'un clustering non supervisé, afin d'obtenir des segments nommés et des recommandations marketing différenciées. La démarche est reproductible : quatre notebooks séquentiels, chacun repartant des fichiers produits par le précédent, et un dépôt documenté.

2. Nettoyage des transactions

Le jeu brut compte **1 067 371 lignes** issues de deux feuilles Excel (déc. 2009 – déc. 2011). Cinq filtres successifs, chacun journalisé et exporté :

Filtre	Lignes retirées	Justification
Doublons exacts	34 335	Artefacts d'export et chevauchement des deux feuilles
Écritures non-produit	5 815	POST, BANK CHARGES, ADJUST... : pas des ventes
Annulations (factures C...)	17 914	Mises de côté pour analyse, non supprimées
CustomerID manquant	232 665	Non rattachables à un client
Quantité ou prix ≤ 0	60	Saisies erronées

Il reste **776 582 transactions, 5 852 clients et 17,1 M€** sur 41 pays.

Un piège non documenté par la source. Les deux feuilles se recouvrent du 1er au 9 décembre 2010 : 1 088 factures y figurent deux fois. Comme nous ajoutons une colonne indiquant la feuille d'origine, un dédoublement naïf ne les détecte pas — les deux copies diffèrent par cette colonne. Il faut dédoubler sur les seules colonnes métier. Sans cette précaution, 22 202 transactions restent comptées double et gonflent la Fréquence et le Montant des clients actifs à cette période, les déplaçant vers les segments haut de gamme. Ce biais ne provoque aucune erreur d'exécution.

Choix assumés. Les écritures non-produit sont exclues car le Montant doit mesurer la valeur des articles achetés, non des frais de port ni des régularisations comptables — arbitrage discutable pour **POST**. À l'inverse, **les montants extrêmes sont conservés** (jusqu'à 168 000 £ sur une ligne) : ce sont de véritables commandes de grossistes, précisément les clients que la segmentation doit isoler. Écrêter au 99e percentile aurait supprimé nos Champions ; l'asymétrie se traite par transformation logarithmique, non par troncature.

(Q1) Les annulations changent-elles les segments ? Non, et nous l'avons mesuré. Deux jeux ont été préparés — l'un excluant les annulations, l'autre les déduisant du CA client — puis segmentés séparément. La comparaison des partitions par Adjusted Rand Index donne **ARI = 0,876** sur les 5 838 clients communs : seuls 289 clients (4,9 %) changent de segment. Trente-sept clients (0,63 %) présentent un CA net nul ou négatif — ils ont retourné autant qu'ils ont acheté — et sont exclus du jeu net, le logarithme étant impossible sur ces valeurs. Nous conservons le jeu sans retours en documentant que ce choix n'est pas structurant. La méthode — refaire tourner et mesurer l'écart — vaut pour toute décision de nettoyage.

3. Features RFM et transformations

Agrégation par client au **snapshot du 10/12/2011**, lendemain de la dernière transaction : la date du jour aurait attribué quinze ans de récence à tous et privé la variable de pouvoir discriminant. La Fréquence compte les **factures distinctes**, non les lignes — une commande de quarante articles reste un acte d'achat.

	Médiane	Moyenne	Maximum	Asymétrie brute	Après log1p
Récence (j)	95	200	739	0,89	-0,49
Fréquence	3	6,3	373	12,04	1,00

	Médiane	Moyenne	Maximum	Asymétrie brute	Après log1p
Montant (£)	856	2 917	580 987	25,33	0,27

(Q2) Pourquoi pas K-means sur les RFM bruts ? K-means minimise une distance euclidienne : sans mise à l'échelle, le Montant (des milliers) écrase la Récence (des centaines) et la Fréquence (des unités), et l'on croirait segmenter sur R, F et M alors qu'on ne segmenterait que sur M. Une asymétrie de 25 signifie en outre qu'une poignée de grossistes est si éloignée du nuage que l'algorithme leur consacrerait des micro-clusters, écrasant 95 % des clients dans un groupe indifférencié. Enfin l'écart pertinent est multiplicatif : en brut, 100 £ → 200 £ et 10 000 £ → 10 100 £ constituent le même écart de 100 £ et pèsent identiquement, alors que le premier client a doublé sa valeur et le second a bougé de 1 %. Le logarithme corrige l'asymétrie (25,33 → 0,27 pour le Montant), la standardisation égalise ensuite le poids des trois dimensions : **deux opérations distinctes pour deux problèmes distincts**. Nous assumons ainsi une pondération égale de R, F et M — décision d'analyste, non propriété des données.

(Q3) La redondance Fréquence / Montant. Après transformation, la corrélation atteint **0,85** contre 0,62 sur données brutes — la corrélation brute était artificiellement basse, les valeurs extrêmes cassant la relation linéaire. Deux variables aussi corrélées pointent dans la même direction : la distance compte « l'intensité d'achat » deux fois et la Récence une seule. Parmi les options possibles (ne rien faire, supprimer M, utiliser le panier moyen, appliquer une PCA), **nous retenons la première en la documentant**. Une PCA décorrèle par construction — PC1 capte 76 % de la variance et forme un axe « valeur client », PC1+PC2 couvrent 95 % — mais exprime les centroïdes en composantes abstraites. Or l'objectif est une segmentation lisible par le marketing : des centroïdes en jours et en livres se défendent devant une direction, une combinaison linéaire non.

4. Clustering et choix de k

K-means (`random_state=42, n_init=20`) est retenu pour son déterminisme et l'interprétabilité de ses centroïdes.

k	Silhouette	Davies-Bouldin ↓	Plus petit groupe	ARI bootstrap
2	0,437	0,874	2 312 —	
3	0,349	1,038	1 217	0,955
4	0,365	0,931	1 184	0,963
5	0,342	0,950	450	0,928
6	0,335	0,962	472	0,890

(Q4) Pourquoi la silhouette ne suffit pas. Notre cas l'illustre : elle est **maximale à k = 2**. En la suivant, nous livrerions « actifs » et « partis » — techniquement optimaux, commercialement inutiles, aucune campagne différenciée ne s'y construisant. Elle mesure une géométrie, non une utilité ; elle favorise mécaniquement les petits k ; elle ignore la taille des clusters ; elle suppose des groupes convexes alors que des données comportementales forment un continuum. Seules ses **variations** importent : elle chute de k=2 à k=3 puis remonte à k=4. Le coude ne tranche pas davantage — le gain marginal passe de 2 224 (k=3) à 1 430 (k=4) puis 818 (k=5), sans angle net : il délimite une zone (3 à 5), pas une valeur.

Nous retenons k = 4 comme point de convergence de quatre indications indépendantes : rebond de silhouette, minimum de Davies-Bouldin, plus petit segment supérieur à 1 100 clients, et surtout la meilleure stabilité. Ce test consiste à tirer vingt sous-échantillons de 80 % des clients, à re-clusteriser chacun et à comparer à la partition de référence : **ARI moyen de 0,963**, minimum 0,893. La variante k = 5, qui isole 450 grossistes concentrant 55 % du CA, est documentée : elle sépare deux groupes appelant la même action marketing, au prix d'un segment plus petit et moins stable.

5. Segments et recommandations

Les segments sont nommés à partir de leurs **valeurs relatives** R/F/M, jamais de leur numéro de cluster — arbitraire et variable d'une exécution à l'autre.

Segment	Effectif	% clients	% CA	Récence moy.	Fréquence moy.	Montant moy.
Champions	1 184	20,2 %	73,4 %	28 j	19,2	10 581 £
À risque	1 454	24,8 %	16,8 %	228 j	5,1	1 974 £
Nouveaux / Prometteurs	1 246	21,3 %	6,1 %	28 j	3,0	841 £
Perdus / Dormants	1 968	33,6 %	3,7 %	393 j	1,4	317 £

Panier moyen : 556 £, 489 £, 313 £, 249 £. Références distinctes par client : 208, 81, 57, 23. Top pays : Royaume-Uni de 82 % à 90 % du CA selon les segments, puis EIRE, Allemagne, France. Top produits communs : Regency Cakestand 3 Tier, White Hanging Heart T-Light Holder.

Un cinquième des clients porte près des trois quarts du chiffre d'affaires. Les 208 références distinctes achetées en moyenne par un Champion, contre 23 pour un dormant, confirment un profil de grossiste et valident rétrospectivement la conservation des montants extrêmes.

- **Champions** — Fidélisation premium : accès anticipé, contact commercial dédié, conditions de gros négociées. *Indicateur : rétention à 12 mois.* Priorité 1 : leur perte serait immédiatement visible au compte de résultat.
- **À risque** — Réactivation ciblée sur leurs références habituelles, offre limitée dans le temps. *Indicateur : réachat à 60 jours.* 2,87 M£ de CA sont exposés.
- **Nouveaux / Prometteurs** — Onboarding : recommandations croisées, remise sur la deuxième commande. *Indicateur : passage à 3 commandes ou plus.*
- **Perdus / Dormants** — Win-back à coût maîtrisé, sans remise agressive ; sortie de la base active si sans réponse. *Indicateur : coût par client réactivé.*

Un contrôle croisé avec la grille RFM par quintiles valide le découpage — les scores moyens décroissent dans le même ordre que le CA (14,1 / 9,8 / 9,7 / 5,0) — et révèle l'apport du clustering : « À risque » et « Nouveaux » obtiennent un score agrégé quasi identique alors que leurs profils sont opposés (bonne fréquence mais 228 jours de récence pour les premiers, achat récent mais trois commandes pour les seconds). Une grille par score les confondrait ; deux actions distinctes s'imposent pourtant.

6. Discussion critique et éthique

(Q5) Défendre la qualité des segments sans vérité terrain. Aucune bonne réponse n'existe contre laquelle se comparer. Notre défense repose sur quatre piliers convergents : la **cohérence interne** (plusieurs métriques indépendantes désignent la même plage de k) ; la **stabilité** (ARI de 0,963 sur vingt rééchantillonnages — les segments ne sont pas l'artefact d'un tirage) ; la **robustesse aux choix de préparation** (ARI de 0,876 entre variantes avec et sans retours) ; la **validité métier**, chaque segment se décrivant en une phrase et appelant une action distincte. La validation réellement externe serait un test A/B, hors périmètre de ce TP.

Ce que nos résultats ne permettent pas de conclure. Nous ne prétendons pas avoir identifié « les vrais » segments. La projection en deux dimensions montre des frontières franches mais aucun vide entre les groupes : les clients forment un **continuum**, et le clustering découpe cet espace à des seuils utiles plutôt qu'il ne révèle des groupes préexistants. Un autre algorithme, un autre k ou un autre snapshot produiraient un découpage différent et tout aussi défendable — c'est d'ailleurs pourquoi la silhouette reste modeste (0,365), ce qui est normal sur des données comportementales.

Autres limites. 21,8 % des lignes n'ont pas d'identifiant client : nos segments décrivent la clientèle identifiée, non l'ensemble des ventes. La concentration du CA sur 1 184 clients est un risque commercial que la segmentation révèle sans le résoudre. Le jeu est à plus de 80 % britannique et orienté grossistes ; la répartition par pays (EIRE à 100 % de Champions) reflète de faibles effectifs et ne doit pas être sur-interprétée. Le RFM est enfin **rétrospectif** : il décrit le passé sans prédire qui rachètera, si bien que les gains de réactivation chiffrés sont des ordres de grandeur servant à hiérarchiser des priorités, non à bâtir un budget.

(Q6) Personnalisation et tarification différenciée : quels garde-fous ? La segmentation rend possible de facturer plus cher les Champions, captifs, en subventionnant l'acquisition des Nouveaux. Cette pratique est **juridiquement encadrée** — une discrimination tarifaire non justifiée par un coût réel peut être illicite et reste déloyale quand le consommateur l'ignore ; **économiquement risquée** — découvrir qu'on paie plus que son voisin détruit la confiance plus sûrement qu'une remise ne fidélise ; **éthiquement problématique** quand le segment devient un proxy d'une caractéristique protégée, le pays ou le pouvoir d'achat se substituant à l'origine ou à la situation sociale.

Nous retenons quatre garde-fous. **Différencier l'attention, pas le prix** : réserver la personnalisation aux avantages plutôt qu'aux tarifs de base — une remise ciblée est acceptable, une majoration ciblée ne l'est pas. **Exclure les variables sensibles et leurs proxys** : notre modèle n'utilise que trois variables comportementales, sans donnée géographique ni démographique, et c'est un choix à préserver. **Garantir la réversibilité** : l'appartenance à un segment se recalcule à chaque période et ne doit jamais devenir une étiquette permanente. **Assurer la transparence** : pouvoir expliquer à un client pourquoi il reçoit telle offre. Le segment « Perdus » appelle une vigilance particulière : cesser d'y investir est défendable en allocation budgétaire, mais ne doit pas dégrader le service auquel ces clients ont droit.