

TAISS 2026 — TOGO AI SUMMER SCHOOL

FILIÈRE F1 · DATA SCIENCE · PROJET FINAL

CLIENT SCOPE RFM PROJECT

Segmentation Clients RFM

Rapport méthodologique — Contexte, méthode, résultats et limites

Chef d'Équipe	Othniel AMADOTO
Membres d'Équipe	1. GAYI Komi Selassi 2. ACOTIE Sam 3. ASSI Magnim Boris 4. Clement TETTEH ASIAKOLEY 5. Selassi GAYI 6. TCHEDRE Aboudoul- 7. Leny NAPALA 8. Esther MOUKPE 9. Othniel AMADOTO 10. BEGUEDOU Essokila Victoire 11. POTCHO Maxime 12. DJOGUENOU Kossi Elom Hervé 13. TENGA Cherif Abdel Azize 14. KADANSAO Koboyo Lucien
Date de soumission	27/08/2026
Dépôt du projet	https://github.com/jack-junior/client-scope-rfm-project
Jeu de données	UCI Online Retail II

Sommaire

Sommaire	3
1. Contexte et problématique	4
2. Méthodologie	4
2.1 Nettoyage des données	4
2.2 Construction des factures RFM	4
Figure — Courbe du coude et score de silhouette	5
Tableau — Critères de choix de k	5
2.4 Caractérisation des segments	6
3. Recommandations marketing par segment	6
4. Discussion critique et éthique	7
5. Réponses aux questions obligatoires du sujet	7
Question 1	7
Question 4	8
Question 5	8
Question 6	8
6. Conclusion	8
8. Interrogation en langage naturel des résultats	9
7. Annexes	9

1. Contexte et problématique

L'e-commerce britannique étudie cumule plus d'un million de transactions sur deux années (décembre 2009 à décembre 2011) et opère principalement en gros auprès d'une clientèle composée à 91 % de clients du Royaume-Uni et de 37 autres pays. En l'absence de typologie client, les actions marketing sont conduites à l'aveugle : les meilleurs acheteurs ne sont pas distingués des clients dormants, les relances ne sont pas ciblées et les promotions sont diffusées de manière uniforme. La mission confiée à l'équipe consiste à construire, à partir des transactions UCI Online Retail II, une segmentation RFM (Récence, Fréquence, Montant) permettant de nommer et caractériser des segments clients actionnables, afin de personnaliser les campagnes et de réduire l'attrition. La méthode développée est directement transposable à un e-commerce ouest-africain ou à une plateforme de paiement mobile, moyennant une adaptation du RFM aux spécificités locales (mobile money, paiements fragmentés).

2. Méthodologie

2.1 Nettoyage des données

Règle appliquée	Justification	% de lignes concernées
Suppression des doublons	Artefacts d'export et chevauchement des deux feuilles	3,22%
Exclusion des écritures non-produites	Codes produit (StockCode) sans partie numérique exploitable (écritures de service, avoirs) : non rattachables à un article réel	0,54%
Traitement des annulations / retours	Factures annulées identifiées par la lettre C et quantités négatives ; conservées séparément dans les deux versions du RFM (achats valides vs global)	1,68%
Suppression des Customer ID manquants	Non rattachable à un client	21,80%

La base initiale contient 1 067 371 lignes et 8 colonnes. Quatre règles de nettoyage ont été appliquées successivement. D'abord, les 34 335 doublons exacts (3,22 %), issus d'artefacts d'export et du chevauchement des deux feuilles annuelles, sont supprimés. Ensuite, les 235 151 lignes sans Customer ID (21,80 %) sont retirées car aucune agrégation au niveau client n'est possible sans identifiant, et l'imputation est inenvisageable ; la base est alors réduite à 797 885 lignes. Les références produit invalides (StockCode sans partie numérique exploitable, ex. codes d'écritures non-produit) sont ensuite exclues (0,54 %), ramenant la base à 794 498 lignes. Enfin, les annulations et retours, identifiées par la lettre C en tête du numéro de facture et par des quantités négatives (1,68 %), sont conservées mais traitées séparément selon deux versions du RFM (achats valides hors annulations, et RFM global incluant les annulations en montant net), ce qui permet de mesurer l'impact du traitement des retours plutôt que de le masquer par suppression. Les prix nuls résiduels sont imputés par le prix moyen observé pour le même produit et le même client afin de préserver la cohérence métier.

2.2 Construction des factures RFM

Deux bases sont préparées à partir des transactions nettoyées : les achats valides (factures ne commençant pas par C, quantités et prix strictement positifs, 776 902 lignes) et l'ensemble des transactions rattachées à un client, annulations incluses (794 498 lignes). La date de référence retenue pour le calcul de la récence est fixée au jour suivant la dernière transaction observée (10 décembre 2011), ce qui évite d'attribuer une récence nulle à un client actif le dernier jour. Pour chacun des 5 856 clients distincts, les trois indicateurs sont calculés par agrégation : `recence_jours` (nombre de jours depuis la dernière transaction), `frequence` (nombre de factures

distinctes) et montant total ou montant global (somme de Quantity x Price). Les distributions brutes sont fortement asymétriques (skewness du montant total = 14,3), ce qui est incompatible avec les hypothèses de K-means. La transformation $\log_{1p}(x) = \log(1 + x)$ est appliquée aux trois variables, avec une variante signée $\text{sign}(x) \times \log_{1p}(|x|)$ pour le montant global qui peut être négatif ; le skewness chute alors à 0,27 (montant), 1,00 (fréquence) et -0,49 (recence). Une standardisation (StandardScaler) est ensuite appliquée pour centrer chaque variable (moyenne nulle, écart-type 1) et placer les trois dimensions RFM sur une échelle comparable avant le cluster ING.

2.3 Clustering et choix de k — Partie 3

Figure — Courbe du coude et score de silhouette




Tableau — Critères de choix de k

Critère	Observation	Conclusion
Coude (inertie)	Cassure marquée entre k=3 (6 339 / 6 476) et k=4 (4 911 / 4 993), puis décroissance quasi linéaire au-delà	Signal en faveur de k=4
Silhouette	Maximum à k=2 (0,438) puis palier local à k=4 (0,365 achats valides / 0,375 RFM global), maintenu jusqu'à k=6	k=2 trop grossier ; k=4 retenu comme meilleur palier exploitable
Coherence métier et taille des segments	k=4 produit quatre profils nettement différenciés (Champions, Fideles en retrait, Occasionnels recents, Endormis) avec des effectifs de 1 186 à 1 970 clients, compatibles avec des campagnes marketing ciblées	Confirme le choix de k=4

La lecture conjointe de l'inertie et du score de silhouette conduit à retenir $k=4$ pour les deux approches (achats valides et RFM global). La silhouette est statistiquement maximale à $k=2$ (0,438), mais deux segments restent trop grossiers pour distinguer les Champions des Fideles en retrait, ni les Occasionnels recents des Endormis : le maximum statistique n'est pas le maximum opérationnel. À $k=4$, la silhouette remonte localement (0,365 pour les achats valides, 0,375 pour le RFM global) et forme un palier qui se maintient jusqu'à $k=6$ avant de décroître, tandis que l'inertie présente une cassure nette entre $k=3$ et $k=4$. Le choix de $k=4$ reflète donc un compromis entre séparation statistique, interprétabilité métier et stabilité de la solution, plutôt qu'une simple lecture du maximum de silhouette.

2.4 Caractérisation des segments

Segment	Effectif	% CA	Récence moy.	Fréquence moy.	Montant moy.	Top pays / produits
Champions	1 186	73,85	28	19,2	10 645	United Kingdom / WORLD WAR 2 GLIDERS, ASSORTED BIRD ORNAMENT, HEART T-LIGHT
Fideles en retrait	1 451	16,30	228	5,1	1 920	United Kingdom / HEART T-LIGHT HOLDER, WORLD WAR 2 GLIDERS, BIRD ORNAMENT
Occasionnels recents	1 249	6,19	28	3,0	848	United Kingdom / WORLD WAR 2 GLIDERS, MINI PAINT SET, POPART WOODEN PENCILS
Endormis	1 970	3,65	393	1,4	317	United Kingdom / WORLD WAR 2 GLIDERS, BUBBLE GUM RING, GRAND CHOCOLATE CANDLE

3. Recommandations marketing par segment

Segment	Recommandation marketing
Champions (1 186 clients, 74 % du CA)	Programme VIP (avant-premières, service dédié, account manager pour les 200 plus gros comptes) et alerte automatique si la cadence d'achat baisse de plus de 30 % sur 60 jours.
Fideles en retrait (1 451 clients, 16 % du CA)	Reactivation ciblée (sondage churn, codes promo personnalisés sur les top produits) via une séquence de trois emails et un appel téléphonique pour les 100 plus gros comptes.

Segment	Recommandation marketing
Occasionnels recents (1 249 clients, 6 % du CA)	Nurturing et montee en frequence par cross-sell sur produits complementaires, contenus educatifs et programme de fidelite progressif des le troisieme achat.
Endormis (1 970 clients, 4 % du CA)	Campagne de reveil avec une offre unique agressive (remise de 20 a 30 %), puis desengagement apres deux tentatives infructueuses ; analyse des canaux d'acquisition correspondants.

4. Discussion critique et éthique

K-means repose sur des hypotheses fortes non respectees ici (clusters spheriques et de taille comparable, alors que les Champions sont denses et peu nombreux tandis que les Endormis sont etales et nombreux), il est sensible a l'initialisation, et le choix de k reste en partie subjectif car le coude et la silhouette ne donnent pas un signal univoque. Le RFM est par ailleurs un modele simplifie qui ignore la saisonnalite, le panier moyen et la geographie. Le jeu de donnees presente en outre des biais notables : forte concentration geographique (91 % UK), suppression de 235 151 lignes sans identifiant client (sous-representation potentielle de certains acheteurs) et periode 2009-2011 correspondant a un contexte economique post-crise difficilement generalisable. Sur le plan ethique, le principal risque est la tarification differenciee par segment : identifier les Champions comme peu sensibles au prix pourrait conduire a leur appliquer des tarifs plus eleves, ce qui pose un probleme d'equite et de transparence, et le profilage peut deriver vers une discrimination indirecte si des variables descriptives sont correlees a des caracteristiques protegees. Six garde-fous sont recommandes : interdiction par charte interne de la tarification differenciee par segment (la segmentation ne doit personnaliser que le contenu des communications) ; plafonnement des ecart de remise au sein d'une meme categorie produit ; transparence via la politique de confidentialite ; droit d'opt-out explicite ; audit annuel d'equite d'accès ; conformite au RGPD europeen et a la CEPDV ouest-africaine avec documentation de la gouvernance algorithmique permettant un audit externe.

5. Réponses aux questions obligatoires du sujet

Question 1

Le traitement des annulations affecte principalement la dimension Montant. Deux versions du RFM ont été calculées : les achats valides (annulations exclues) et le RFM global (annulations incluses, montant net). Le montant moyen des Champions passe de 10 645 £ à 10 672 £, soit un écart de seulement 0,3 %, ce qui suggère que les annulations des gros clients restent proportionnées à leurs achats. Pour certains clients atypiques, le montant net peut toutefois devenir négatif lorsque les retours dépassent les achats, ce qui justifie l'utilisation d'une transformation logarithmique signée. L'impact peut être vérifié en comparant les deux segmentations à l'aide de l'Adjusted Rand Index (ARI) et en analysant les clients dont le segment change. Dans notre cas, les écarts d'effectifs restent modérés : Champions (1 186 vs 1 101) et Fidèles (1 451 vs 1 481). L'impact des annulations apparaît donc limité, mais non négligeable.

Question 2

Trois raisons justifient la chaîne $\log_{1p}$ + StandardScaler. D'abord, les échelles sont hétérogènes : la récence varie de 0 à 739 jours, la fréquence de 1 à 375 factures et le montant de 3 à 580 987 £. Sans standardisation, le montant dominerait les distances euclidiennes et K-means produirait des segments quasi unidimensionnels. Ensuite, les distributions sont fortement asymétriques (skewness du montant = 14,3). La transformation $\log_{1p}$ réduit cette asymétrie à 0,27 pour le montant, 1,00 pour la fréquence et -0,49 pour la récence, en compressant les valeurs extrêmes sans les supprimer. Enfin, StandardScaler place les trois dimensions RFM sur une échelle comparable (moyenne = 0, écart-type = 1), permettant à K-means de les pondérer équitablement. Le gain est mesurable : à k = 4, le score de silhouette passe de valeurs proches de 0 sur les données brutes à 0,365 après transformation.

Question 3

La fréquence et le montant sont typiquement très corrélés dans les données e-commerce (Spearman souvent $> 0,8$), car un client qui achète souvent a tendance à dépenser plus. Cette redondance introduit un double poids sur la dimension « intensité d'achat » dans K-means, ce qui peut biaiser les segments en la faisant apparaître plus importante par rapport à la récurrence. Trois approches sont possibles : (1) appliquer une Analyse en Composantes Principales (PCA) sur les features standardisées et retenir les deux premières composantes orthogonales ; (2) remplacer fréquence et montant par une variable unique (panier moyen = montant / fréquence), ce qui supprime la redondance mais fait perdre l'information de volume ; (3) accepter la corrélation et la documenter par une analyse de robustesse (relancer K-means en retirant une des deux variables et vérifier la stabilité). Si les segments sont stables, la redondance n'affecte pas la conclusion métier ; s'ils basculent, la PCA est recommandée pour la version finale.

Question 4

Le score de silhouette présente quatre limites. D'abord, il est maximal pour $k=2$ (0,438 pour les achats valides), mais deux segments sont insuffisants pour distinguer les Champions des Fidèles en retrait, ni les Endormis des Occasionnels : le maximum statistique n'est pas le maximum opérationnel. Ensuite, la silhouette ne dit rien de la stabilité : un même k peut donner des segments différents selon l'initialisation, et seul un test bootstrap (ARI moyen) permet de juger cette stabilité. La taille des segments est également cruciale : un $k=8$ peut produire un segment de 30 clients, statistiquement bien séparé mais commercialement inexploitable. Enfin, la cohérence métier doit primer : un $k=4$ qui produit quatre profils nettement différenciés est plus utile qu'un $k=7$ avec plusieurs segments proches, même si la silhouette est légèrement supérieure. La bonne pratique consiste à croiser quatre critères : le coude sur l'inertie, la silhouette (en cherchant un palier plutôt qu'un maximum absolu), la stabilité par bootstrap et la cohérence métier. Dans ce projet, $k=4$ émerge comme compromis optimal : cassure marquée sur l'inertie, palier local de silhouette à 0,365-0,375, quatre profils bien séparés et tailles de segments compatibles avec des campagnes marketing (1 186 à 1 970 clients).

Question 5

L'absence de vérité terrain impose une validation indirecte multi-critères. Cinq approches sont combinées : (1) la stabilité par bootstrap (relancer K-means sur B échantillons et mesurer l'ARI moyen, un $ARI > 0,8$ indiquant une segmentation robuste) ; (2) la cohérence métier (les segments doivent présenter des profils RFM nettement différenciés et être interprétables en termes marketing) ; (3) la comparaison des deux approches RFM (achats valides vs global), la concordance des segments validant la robustesse à la définition du Montant ; (4) la validation externe par l'équipe marketing (soumettre les profils des segments et collecter un retour métier) ; (5) la vérification a posteriori par une campagne test (appliquer des actions différentielles par segment et mesurer les taux de réponse). Dans notre cas, les segments passent avec succès les quatre premiers critères : effectifs cohérents (1 100 à 2 000 clients), profils nettement différenciés (recense de 28 à 393 jours, fréquence de 1,4 à 19,2, montant de 317 à 10 645), faible écart entre les deux approches et dénomination métier immédiatement comptable. La cinquième validation (campagne test) est une perspective naturelle de prolongement.

Question 6

La tarification différenciée par segment est le risque éthique principal : un e-commerce qui identifie ses Champions comme peu sensibles au prix peut être tenté de leur appliquer des tarifs plus élevés, ce qui pose un problème d'équité (un client fidèle paie plus cher qu'un nouveau) et de transparence (le client n'est pas informé). Pour éviter cette dérive, six garde-fous sont recommandés : (1) interdire par charte interne la tarification différenciée par segment, la segmentation devant servir à personnaliser le contenu des communications, pas le prix ; (2) plafonner les écarts de remise et appliquer les remises uniformément au sein d'une même catégorie de produit, indépendamment du segment ; (3) garantir la transparence via une mention dans la politique de confidentialité ; (4) offrir un droit d'opt-out explicite et facilement exerçable ; (5) conduire un audit annuel d'équité d'accès, vérifiant que tous les segments bénéficient à proportion des mêmes promotions ; (6) respecter le RGPD européen et la CEPDV ouest-africaine (base juridique, droit d'information, droit d'opposition) et documenter la gouvernance algorithmique (documentation des choix de segmentation, traçabilité des segments affectés, possibilité d'audit externe).

6. Conclusion

Ce travail pratique a permis de construire une segmentation clients RFM opérationnelle à partir du jeu UCI Online Retail II, en suivant un pipeline reproductible de quatre étapes. Les quatre segments obtenus (Champions, Fidèles en retrait, Occasionnels récents, Endormis) présentent des profils nettement différenciés, sont interprétables en termes marketing et donnent lieu à des recommandations actionnables par segment. La concentration de type Pareto du chiffre d'affaires sur les Champions (74 % du CA pour 20 % des clients) constitue un constat métier majeur qui justifie une approche différenciée des campagnes.

Plusieurs perspectives sont envisageables : enrichir le RFM avec des variables comportementales (panier moyen, diversité des produits, saisonnalité, canal d'acquisition) ; tester d'autres algorithmes (DBSCAN pour les outliers, K-prototypes pour intégrer Country en variable catégorielle, GMM pour assouplir l'hypothèse de sphéricité) ; mettre en place un monitoring du drift de la segmentation avant déploiement en production. Sur le plan éthique, les garde-fous proposés (interdiction de la tarification par segment, plafonds de remise, transparence, opt-out, audits annuels, conformité RGPD/CEPDV) constituent un cadre minimal de gouvernance algorithmique. La transposabilité de la méthode à un e-commerce ouest-africain ou à une plateforme de paiement mobile suppose une attention particulière au contexte réglementaire local et à la diversité des comportements de paiement (mobile money, paiements fragmentés, épisodes de crédit), qui peuvent enrichir le RFM traditionnel.

7. Interrogation en langage naturel des résultats

Une couche d'interrogation en langage naturel a été ajoutée afin de permettre l'exploration des résultats de la segmentation RFM sans avoir à manipuler directement les données ou le code. Cette fonctionnalité a été réalisée à partir du projet open source OpenMind RAG, adapté pour exploiter les résultats et les interpréter à l'aide d'un système de Retrieval-Augmented Generation (RAG).

Les résultats de la segmentation ainsi que les informations décrivant les différents profils clients sont d'abord transformés en documents, découpés en fragments puis vectorisés à l'aide de modèles d'embeddings. Ces représentations sont stockées dans une base vectorielle ChromaDB, permettant d'effectuer une recherche sémantique à partir d'une question formulée en langage naturel.

Lorsqu'un utilisateur pose une question, le système recherche les informations les plus pertinentes dans la base vectorielle, puis applique un re-ranking afin d'améliorer la sélection des résultats. Les informations récupérées sont ensuite transmises à un LLM qui génère une réponse contextualisée. Les réponses sont accompagnées de citations permettant d'identifier les sources utilisées.

L'architecture mise en place repose ainsi sur plusieurs composants : LangChain pour le pipeline RAG, sentence-transformers pour les embeddings et le re-ranking, ChromaDB pour le stockage vectoriel et un LLM accessible via Groq pour la génération des réponses. Une interface conversationnelle permet ensuite d'interroger directement les résultats de la segmentation.

Cette couche permet par exemple de poser des questions telles que : « Quel segment génère la plus grande part du chiffre d'affaires ? », « Quels sont les profils des Champions ? » ou « Quelle stratégie marketing recommander pour les clients Endormis ? ». L'objectif est donc de transformer les résultats analytiques en une base de connaissances interrogeable en langage naturel, facilitant leur interprétation et leur utilisation par des profils non techniques.

La fonctionnalité a été implémentée à partir du projet open source OpenMind RAG : <https://github.com/cherif-tg/openmind>

8. Annexes

Liens utiles : dépôt du projet, notebooks, environnement reproductible.

- **Dépôt GitHub** : <https://github.com/jack-junior/client-scope-rfm-project>
- **OpenMind Rag** : <https://github.com/cherif-tg/openmind>
- **Notebooks (01 à 04)** : 01_nettoyage.ipynb, 02_features_rfm.ipynb, 03_clustering_choix_k.ipynb, 04_caracterisation.ipynb (module réutilisable src/clustering.py)

